

TB075/86.53 Procesamiento del Habla

Guía de ejercicios 2C 2026

Facultad de Ingeniería, Universidad de Buenos Aires

Dr. Kevin Michalewicz

Este documento concentra las consignas de las doce clases prácticas (P1 a P12). Está pensado como material de pizarrón y también para realizar en el hogar en caso de que algún ejercicio no se llegue a completar en clase. La parte de implementación en Python se encuentra en los notebooks asociados, referenciados al final de cada práctica.

La notación coincide con la vista en clase. Por ejemplo: $x_c(t)$ señal continua; $x[n]$ señal discreta; $\mathbf{y}_t$ vector de features para el frame t ; $\lambda = (A, B, \boldsymbol{\pi})$ parámetros de un Modelo Oculto de Markov; $\alpha_t(i)$, $\beta_t(i)$, $\delta_t(i)$ variables de forward, backward y Viterbi; $\gamma_t(i)$ y $\xi_t(i, j)$ probabilidades *a posteriori* de estado y transición.

Índice

P1: Repaso de Procesamiento Digital de Señales	2
P2: Análisis fonético	3
P3: Coeficientes Cepstrales en las Frecuencias de Mel	4
P4: Modelo de Mezcla Gaussiana	5
P5: Modelos Ocultos de Markov	6
P6: Reconocedor de dígitos con GMM-HMM	7
P7: Modelos de lenguaje n-grama	8
P8: Redes neuronales para habla	9
P9: Detección de palabras clave con CNN-BiLSTM	10
P10: CTC y alineamiento	11
P11: ASR con modelos fundacionales	12
P12: Síntesis de voz y evaluación	13

P1: Repaso de Procesamiento Digital de Señales

Objetivos. Recuperar fluidez en la representación de una señal en tiempo y frecuencia. Estudiar los parámetros básicos de la Transformada de Fourier de Tiempo Corto (STFT). Distinguir frecuencia fundamental matemática de *pitch* percibido.

Ejercicio 1. Discriminación espectral de dos senoides

Sea la señal continua $x_c(t) = A \cos(2\pi f_1 t) + B \cos(2\pi f_2 t)$, con $f_1 = 100$ Hz, $f_2 = 200$ Hz, $A = B = 1$, muestreada a $f_s = 500$ Hz para obtener $x[n] = x_c(nT_s)$.

- Calcular analíticamente el espectro $X_c(\Omega)$ de $x_c(t)$ y el espectro $X(\omega)$ de $x[n]$ para $f_s > 2f_{\max} = 400$ Hz.
- Tomando una ventana temporal $x_t[n]$ de duración L muestras, determinar el menor L y el menor N_{FFT} que hacen evidente la presencia de las dos senoidales en el espectro discreto. Justificar usando la respuesta en frecuencia de la ventana rectangular.

Ejercicio 2. Pitch matemático vs. pitch percibido

Para una señal $x_c(t) = A \cos(2\pi f_1 t) + B \cos(2\pi f_2 t)$, determinar el período fundamental T_0 y la frecuencia fundamental $F_0 = 1/T_0$ en cada caso.

- $f_1 = 220$ Hz, $f_2 = 440$ Hz, $A = B = 1$.
- $f_1 = 220$ Hz, $f_2 = 660$ Hz, $A = 2, B = 1$.
- $f_1 = 660$ Hz, $f_2 = 880$ Hz, $A = 1, B = 0,1$.

¿Qué papel juegan A y B en la definición de F_0 matemáticamente? ¿Y perceptualmente? Anticipar qué se va a escuchar antes de sintetizar.

Notebook

Acceder al archivo `P1_Intro.ipynb`. En el ejercicio 3 comparamos los resultados de los ejercicios 1 y 2 con sus versiones obtenidas computacionalmente. Luego se proponen los ejercicios 4 y 5 que cubren el cómputo de espectrogramas y DTMF.

P2: Análisis fonético

Objetivo. Familiarizarse con la lectura de espectrogramas de habla real, identificar fonemas y formantes, e interpretar la prosodia (F_0).

Ejercicio 1. Predicción de formantes

Para las cinco vocales del español $/a/$, $/e/$, $/i/$, $/o/$, $/u/$:

- (a) Indicar la posición articulatoria (anterior, central, posterior) y la abertura (cerrada, media, abierta).
- (b) Predecir el orden cualitativo de F_1 y F_2 . Justificar.
- (c) Dibujar a mano alzada el diagrama (F_1, F_2) de las cinco vocales.

Ejercicio 2. Influencia del hablante

El tracto vocal femenino es aproximadamente un 15 % más corto que el masculino (estadísticamente hablando). Predecir el efecto sobre F_1, F_2, F_3 y sobre F_0 . ¿Cómo afecta esto al diseño de un sistema de ASR si entrena solamente con voces masculinas?

Notebook

Acceder al archivo `P2_Fonetica.ipynb`. En el ejercicio 3 sintetizamos las cinco vocales por modelo fuente-filtro, en el ejercicio 4 verificamos lo obtenido en el ejercicio 1, y en el ejercicio 5 interpretamos el espectrograma de una frase corta.

P3: Coeficientes Cepstrales en las Frecuencias de Mel

Objetivo. Entender el pipeline MFCC como una representación compacta de la envolvente espectral. Diseñar un banco mel simple, interpretar el rol del logaritmo y de la DCT, e implementar MFCC en Python sobre señales de habla sintética.

Ejercicio 1. Banco de filtros en la escala mel

Queremos construir un banco de $M = 5$ filtros triangulares entre $f_{\min} = 100$ Hz y $f_{\max} = 4000$ Hz. Usamos

$$\text{mel}(f) = 2595 \log_{10} \left(1 + \frac{f}{700} \right), \quad f(\text{mel}) = 700 \left(10^{\text{mel}/2595} - 1 \right).$$

- Convertir 100 Hz y 4000 Hz a escala mel.
- Para construir 5 filtros triangulares, explicar por qué es necesario considerar $M+2 = 7$ frecuencias.
- Distribuir esos 7 puntos equiespaciados en escala mel y convertirlos a Hz. Identificar las 5 frecuencias centrales.
- Esbozar cualitativamente los filtros. ¿Por qué se ensanchan en Hz al aumentar la frecuencia?

Ejercicio 2. Del espectro al vector MFCC

Considerar el pipeline de MFCC para un frame $x_t[n]$:

$$x_t[n] \longrightarrow S[k, t] \longrightarrow E_m[t] \longrightarrow \tilde{E}_m[t] \longrightarrow c_d[t].$$

- Indicar qué representa cada cantidad: $S[k, t]$, $E_m[t]$, $\tilde{E}_m[t]$ y $c_d[t]$.
- Explicar por qué se toma logaritmo antes de la DCT. Relacionar con compresión de rango dinámico y con el modelo fuente-filtro.
- Explicar por qué la DCT es útil al considerar GMM con covarianza diagonal.
- Si se conservan $C = 13$ coeficientes estáticos y se agregan deltas y delta-deltas, ¿cuál es la dimensión final D del vector $\mathbf{y}_t$?

Notebook

Acceder al archivo `P3_MFCC.ipynb`. En el ejercicio 3 implementamos el pipeline MFCC desde cero para una señal de habla sintética. En el ejercicio 4 verificamos empíricamente que la DCT reduce correlaciones entre dimensiones y permite justificar el uso de covarianzas diagonales en GMM.

P4: Modelo de Mezcla Gaussiana

Objetivos. Aplicar la regla MAP con modelos gaussianos, realizar un paso del algoritmo EM para una mezcla gaussiana e interpretar estas densidades como modelos de emisión para Modelos Ocultos de Markov.

Ejercicio 1. Verosimilitud gaussiana de una vocal

Sea $\mathbf{y} = [500 \ 1500]^\top$ Hz un punto del plano (F_1, F_2) . Evaluar su log-verosimilitud bajo una clase modelada por

$$\boldsymbol{\mu} = \begin{bmatrix} 300 \\ 2200 \end{bmatrix}, \quad \boldsymbol{\Sigma} = \begin{bmatrix} 1600 & 0 \\ 0 & 10000 \end{bmatrix}.$$

- (a) Calcular la distancia de Mahalanobis al cuadrado

$$\delta^2 = (\mathbf{y} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{y} - \boldsymbol{\mu}).$$

- (b) Calcular $\log p(\mathbf{y})$ usando la densidad gaussiana en $\mathbb{R}^2$.
- (c) Interpretar el resultado: ¿es razonable asignar $\mathbf{y}$ a esa clase? ¿Qué vocal del español podría corresponder a la media $\boldsymbol{\mu}$?

Ejercicio 2. Un paso de EM

Sea un dataset unidimensional con tres observaciones:

$$y^{(1)} = 1, \quad y^{(2)} = 2, \quad y^{(3)} = 5.$$

Se modela con una GMM de dos componentes, con parámetros iniciales

$$\omega_1 = \omega_2 = 0,5, \quad \mu_1 = 1,5, \quad \mu_2 = 4,5, \quad \sigma_1^2 = \sigma_2^2 = 1.$$

Para que el cálculo analítico sea razonable, mantener las varianzas fijas en 1 y hacer un paso de EM solo para pesos y medias.

- (a) Paso E: calcular las responsabilidades

$$\gamma_{im} = P(Z^{(i)} = m | Y^{(i)} = y^{(i)}).$$

- (b) Paso M: reestimar ω_m y μ_m .
- (c) Interpretar: ¿qué componente explica principalmente a cada punto? ¿Por qué el punto $y = 2$ no queda asignado con responsabilidad exactamente 1 a la primera componente?

Notebook

Acceder al archivo `P4_GMM.ipynb`. En el ejercicio 3 verificamos numéricamente el cálculo de los ejercicios 1 y 2 y comprobamos que un paso de EM aumenta la log-verosimilitud. En el ejercicio 4 entrenamos un clasificador generativo de vocales en el plano (F_1, F_2) usando gaussianas/GMM y visualizamos sus regiones de decisión.

P5: Modelos Ocultos de Markov

Objetivo. Calcular las cantidades básicas de un Modelo Oculto de Markov discreto: forward, backward, probabilidades *a posteriori* de estado y camino de Viterbi.

Tomemos un HMM de $N = 2$ estados y dos símbolos de observación $\mathcal{V} = \{\mathbf{x}, \mathbf{z}\}$. Los parámetros son

$$\boldsymbol{\pi} = \begin{bmatrix} 0,6 \\ 0,4 \end{bmatrix}, \quad A = \begin{bmatrix} 0,7 & 0,3 \\ 0,4 & 0,6 \end{bmatrix}, \quad B = \begin{bmatrix} 0,9 & 0,1 \\ 0,2 & 0,8 \end{bmatrix}.$$

La fila j de B da las probabilidades de emisión desde el estado j , mientras que la primera columna corresponde a $\mathbf{x}$ y la segunda a $\mathbf{z}$. La secuencia observada es

$$y_{1:3} = (\mathbf{x}, \mathbf{z}, \mathbf{x}).$$

Ejercicio 1. Forward y backward

- (a) Calcular $\alpha_t(i)$ para $t = 1, 2, 3$ e $i = 1, 2$.
- (b) Calcular $P(y_{1:3}|\lambda) = \sum_i \alpha_3(i)$. ¿Por qué usamos como notación P en vez de p ?
- (c) Calcular $\beta_t(i)$ para $t = 3, 2, 1$.
- (d) Verificar que

$$\sum_i \alpha_t(i) \beta_t(i) = P(y_{1:3}|\lambda)$$

para $t = 1, 2, 3$.

Ejercicio 2. Decodificación por probabilidad *a posteriori* y por Viterbi

- (a) Calcular

$$\gamma_t(i) = P(Q_t = i | Y_{1:3} = y_{1:3}, \lambda) = \frac{\alpha_t(i) \beta_t(i)}{P(y_{1:3}|\lambda)}.$$

Verificar que $\sum_i \gamma_t(i) = 1$ para cada t .

- (b) Decodificar por probabilidad *a posteriori* local:

$$\hat{q}_t^{\text{local}} = \arg \max_i \gamma_t(i).$$

- (c) Calcular $\delta_t(i)$ y $\psi_t(i)$ (Viterbi).
- (d) Determinar el camino más probable $q_{1:3}^*$ y computar

$$P^* = \max_{q_{1:3}} P(Q_{1:3} = q_{1:3}, Y_{1:3} = y_{1:3} | \lambda).$$

- (e) ¿Coinciden los resultados de los ítemos (b) y (d) en este caso? ¿Y en general? ¿Qué tan robusto es cada uno a las transiciones prohibidas?

Notebook

Acceder al archivo `P5_HMM.ipynb`. En este ejercicio único replicamos los cálculos, implementamos las recursiones de forma general y visualizamos las cantidades sobre el trellis.