

Entrega 1

TB075/86.53 Procesamiento del Habla

Facultad de Ingeniería - UBA

17 de septiembre de 2026

Los ejercicios 1 y 2 se resuelven a mano. El código de los ejercicios 3 y 4 se completa en `Entrega_1.ipynb`, pero sus interpretaciones se responden a mano. En los ejercicios 3 y 4, la función `enmarcar` conserva únicamente frames completos y no agrega *padding*. Por lo tanto, cada señal de 0,6 segundos produce 58 frames.

Ejercicio 1

En un frame estacionario se considera el modelo fuente-filtro

$$X(e^{j\omega}) = E(e^{j\omega})H(e^{j\omega}).$$

A partir de este modelo se comparan tres señales. La señal A, $x_A[n]$, es una /a/ con $F_0 = 100$ Hz; la señal B es $x_B[n] = 4x_A[n]$; y la señal C, $x_C[n]$, tiene el mismo tracto vocal y nivel que A, pero $F_0 = 200$ Hz. Se utilizan

$$f_s = 16 \text{ kHz}, \quad L = 400, \quad N_{\text{FFT}} = 512, \quad M = 26,$$

y se conservan 13 coeficientes MFCC.

(a) Comparar A y C en cuanto a la ubicación de los formantes y a la separación de los armónicos. Esbozar ambos espectros.

(b) Seguir el cambio al pasar de A a B a través de

$$S[k, t] \longrightarrow E_m[t] \longrightarrow \tilde{E}_m[t] \longrightarrow c_d[t].$$

¿Qué MFCC cambia al comparar A y B? ¿Aumenta o disminuye? Justificar.

(c) Indicar las dimensiones del espectro no redundante, del vector log-mel, de los MFCC estáticos y del vector con deltas y delta-deltas.

Ejercicio 2

Para una observación $\mathbf{y}$ se conocen:

Clase s_k	$P(S = s_k)$	ω_{k1}	ω_{k2}	$\mathcal{N}_{k1}(\mathbf{y})$	$\mathcal{N}_{k2}(\mathbf{y})$
/a/	0,75	0,80	0,20	0,06	0,18
/i/	0,25	0,30	0,70	0,20	0,10

(a) Calcular $p(\mathbf{y}|S = \text{/a/})$ y $p(\mathbf{y}|S = \text{/i/})$.

(b) Calcular, para cada clase,

$$\gamma_{km} = P(Z = m | \mathbf{Y} = \mathbf{y}, S = s_k).$$

(c) Clasificar $\mathbf{y}$ por máxima verosimilitud y por MAP. ¿Coinciden?

(d) Explicar por qué no se elige simplemente la mayor densidad gaussiana individual.

Ejercicio 3

Usar las funciones provistas en el notebook sin modificar sus parámetros. Construir cuatro señales de 0,6 segundos:

- A: /a/, $F_0 = 120$ Hz;
- B: la señal A multiplicada por 0,25;
- C: /a/, $F_0 = 200$ Hz;
- D: /i/, $F_0 = 120$ Hz.

- (a) Calcular la matriz de MFCC de cada señal y su promedio temporal. Graficar los cuatro vectores medios.
- (b) Tomando el vector MFCC medio de A como referencia, calcular su distancia euclídea a los vectores medios de B, C y D:

$$d(\mathbf{a}, \mathbf{b}) := \|\mathbf{a} - \mathbf{b}\|_2.$$

Comparar utilizando primero el vector completo $[c_0, \dots, c_{12}]^T$ y luego $[c_1, \dots, c_{12}]^T$, obtenido al excluir el coeficiente c_0 .

- (c) Anticipar el orden de las distancias y luego interpretar el resultado en términos del nivel, F_0 , la vocal en sí, el logaritmo aplicado y la DCT.

Ejercicio 4

Generar dos señales /a/ de 0,6 segundos, nivel unitario y $F_0 \in \{100, 200\}$ Hz. Concatenar sus frames MFCC y entrenar una única GMM de dos componentes y covarianza diagonal, usando la configuración provista.

- (a) Entrenar el modelo usando el vector completo

$$[c_0, \dots, c_{12}]^T.$$

Obtener con `predict_proba` las responsabilidades de cada frame y calcular su promedio para cada señal. ¿Qué componente explica principalmente cada valor de F_0 ? Recordar que los índices de las componentes son arbitrarios.

- (b) Generar dos señales adicionales:

- la /a/ de 100 Hz multiplicada por 0,25;
- una /i/ de 100 Hz y nivel unitario.

Para cada señal, calcular la log-verosimilitud media

$$\ell = \frac{1}{T} \sum_{t=1}^T \log p(\mathbf{y}_t).$$

- (c) Repetir el entrenamiento y la evaluación usando solamente $[c_1, \dots, c_{12}]^T$, es decir, excluyendo c_0 .
- (d) Comparar los resultados. Explicar qué variabilidad representan las dos componentes, qué efecto produce eliminar c_0 y por qué la /i/ debería obtener menor verosimilitud que las señales /a/.