

Simulacro de parcial

TB075/86.53 Procesamiento del Habla

Facultad de Ingeniería - UBA

9 de octubre de 2026

El ejercicio 1 se resuelve a mano. El ejercicio 2 se completa enteramente en `Simulacro.ipynb`, incluidas sus interpretaciones en celdas Markdown. En el ejercicio 3, los ítems (a) y (b) se resuelven a mano y los restantes en el notebook. Todo resultado numérico debe acompañarse con una interpretación.

Ejercicio 1

Se considera un HMM *left-to-right* de dos estados con emisiones gaussianas unidimensionales. Para la secuencia

$$y_{1:4} = (-1, 0, 3, 4),$$

un paso E de Baum-Welch produjo

$$\Gamma = [\gamma_t(i)] = \begin{bmatrix} 0,95 & 0,05 \\ 0,80 & 0,20 \\ 0,25 & 0,75 \\ 0,05 & 0,95 \end{bmatrix}, \quad \sum_{t=1}^3 [\xi_t(i, j)] = \begin{bmatrix} 1,10 & 0,90 \\ 0 & 1,00 \end{bmatrix}.$$

La distribución inicial permanece fija en el primer estado y la transición de 2 a 1 está prohibida.

- (a) [0.5p] Calcular el número esperado de frames $N_i = \sum_t \gamma_t(i)$ asignado a cada estado.
- (b) [1p] Reestimar la matriz de transición A . ¿Qué posición vale cero y por qué?
- (c) [1p] Reestimar la media y la varianza de la gaussiana de cada estado.
- (d) [0.5p] Bajo la matriz actualizada, calcular la duración media en el estado 1. Expresarla en frames y en milisegundos para un hop de 10 ms.

Ejercicio 2

En el notebook se generan observaciones sintéticas bidimensionales que representan dos features acústicos. Los parámetros son

$$\boldsymbol{\mu}_a = [-2, 1]^T, \quad \boldsymbol{\mu}_i = [2, -1]^T, \quad \Sigma = 0,45^2 I.$$

Se forman dos pseudopalabras: `/ai/` y `/ia/`. Cada realización contiene n frames de la primera vocal y n de la segunda, con $n \in \{8, \dots, 12\}$. Se proveen 30 secuencias de entrenamiento y 12 de test por clase (generadas con una semilla fija).

Se entrena un HMM gaussiano *left-to-right* de dos estados por pseudopalabra empleando segmentación uniforme. La distribución inicial está fija en el estado 1, sólo se permiten *self-loop* y avance, y para calcular el score se exige terminar en el estado 2.

- (a) [1p] Usar las funciones provistas para estimar un modelo por pseudopalabra. Inspeccionar las medias aprendidas en sus dos estados y relacionarlas con el orden de las vocales.
- (b) [1p] Entrenar ambos modelos, clasificar las secuencias de prueba por máxima verosimilitud y mostrar la matriz de confusión.
- (c) [0.5p] Calcular el vector medio de todos los frames de entrenamiento de cada clase y la distancia euclídea entre esos dos vectores.
- (d) [1p] Responder en Markdown: ¿por qué el promedio temporal casi no distingue las clases y el HMM sí? Relacionar la respuesta con el papel de los estados y de las transiciones.

Ejercicio 3

Sea

$$x_c(t) = \sum_{h=3}^{10} \frac{1}{h} \cos(2\pi h F_0 t), \quad F_0 = 120 \text{ Hz}.$$

La señal se muestrea a $f_s = 8000$ Hz durante 0,2 s. En el notebook se analiza una ventana de Hanning de toda la señal con $N_{\text{FFT}} = 4096$.

- (a) [0.75p] Determinar el período fundamental de $x_c(t)$. ¿Hay una línea espectral en F_0 ?
- (b) [1p] Indicar las frecuencias de las líneas espectrales y predecir en qué quefrecia debería aparecer el pico asociado a la periodicidad armónica. En una señal de habla, indicar qué información se espera en quefrecias bajas y cuál alrededor de $1/F_0$.
- (c) [0.75p] A partir del espectro de magnitud ya calculado en el notebook, completar solamente el cálculo del cepstrum real

$$c[n] = \text{IDFT}\{\log(|X[k]| + \varepsilon)\}.$$

- (d) [1p] Buscar el máximo cepstral solamente en el rango de pitch 70-300 Hz, estimar F_0 y graficar espectro y cepstrum con ejes físicos. Explicar en Markdown por qué puede recuperarse F_0 aunque su componente espectral no esté presente y por qué se restringe la búsqueda.

Hoja de Fórmulas

DFT y cepstrum

$$X[k] = \sum_{n=0}^{L-1} x[n]w[n]e^{-j2\pi kn/N_{\text{FFT}}}$$

$$f_k = \frac{k f_s}{N_{\text{FFT}}}$$

$$c[n] = \text{IDFT}\{\log(|X[k]| + \varepsilon)\}$$

$$q_n = \frac{n}{f_s}$$

Gaussiana (diagonal)

$$\log \mathcal{N}(\mathbf{y}; \boldsymbol{\mu}, \Sigma) = -\frac{1}{2} \left[D \log(2\pi) + \sum_{d=1}^D \log \sigma_d^2 + \sum_{d=1}^D \frac{(y_d - \mu_d)^2}{\sigma_d^2} \right]$$

$$b_i(\mathbf{y}) = \sum_{m=1}^{M_i} \omega_{im} \mathcal{N}(\mathbf{y}; \boldsymbol{\mu}_{im}, \Sigma_{im})$$

Forward

$$\alpha_1(i) = \pi_i b_i(\mathbf{y}_1)$$

$$\alpha_t(j) = b_j(\mathbf{y}_t) \sum_i \alpha_{t-1}(i) a_{ij}$$

Probabilidades *a posteriori* (HMM)

$$\gamma_t(i) = P(Q_t = i | \mathbf{y}_{1:T}, \lambda)$$

$$\xi_t(i, j) = P(Q_t = i, Q_{t+1} = j | \mathbf{y}_{1:T}, \lambda)$$

Baum-Welch

$$N_i = \sum_{t=1}^T \gamma_t(i)$$

$$a_{ij}^{\text{nuevo}} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)}$$

Emisión gaussiana unidimensional:

$$\mu_i^{\text{nuevo}} = \frac{\sum_t \gamma_t(i) y_t}{N_i}$$

$$(\sigma_i^2)^{\text{nuevo}} = \frac{\sum_t \gamma_t(i) (y_t - \mu_i^{\text{nuevo}})^2}{N_i}$$

Duración

$$P(D_i = d) = a_{ii}^{d-1} (1 - a_{ii})$$

$$\mathbb{E}[D_i] = \frac{1}{1 - a_{ii}}$$

Viterbi

$$\delta_1(i) = \pi_i b_i(\mathbf{y}_1)$$

$$\delta_t(j) = b_j(\mathbf{y}_t) \max_i \delta_{t-1}(i) a_{ij}$$